

ДОМАШНЕЕ ЗАДАНИЕ 1 · ПЕРВАЯ НЕДЕЛЯ

Свежие вопросы и агент, который на них отвечает

Выдано на семинаре 13.09. Дедлайн воскресенье 20.09, 23:59. Сдаётся ссылкой на git-репозиторий в чат курса. Обязательная часть оценивается из десяти баллов, опциональная даёт бонус и задел на финальный проект.

Зачем это задание

Тезис курса: хороший агент на дешёвой модели обходится дешевле сильной модели в одинокую при том же качестве. На семинаре мы проверяли его на школьной арифметике, где сильной модели инструменты не нужны. Теперь проверим там, где они нужны любой модели: на событиях, которых не было в обучающих данных. Sonnet 4.6 не знает, что случилось в 2026 году. Агент с поиском может узнать. Вопрос в том, насколько дешевле и насколько надёжнее.

Часть 1, обязательная: датасет и агент

Шаг 1. Датасет свежих вопросов

Нужен набор вопросов о событиях после 2025 года с короткими проверяемыми ответами. У каждого вопроса четыре поля: сам вопрос, ответ, ссылка на источник и цитата из источника, в которой ответ содержится дословно.

Стартовый набор лежит в репозитории семинара: `data/fresh_2026.jsonl`, 125 вопросов. Он собран автоматически скриптом `fetch_fresh.py`: факты с датами из шестидесяти с лишним обзорных статей Википедии про 2026 год (страны, науки, виды спорта), из каждого дешёвая модель сделала вопрос с коротким ответом, дальше оставлены только те, на которые Sonnet 4.6 без инструментов ответил неверно: на 107 из 125 он честно написал «unknown», на 18 назвал не тот факт. В каждой записи есть поле `evidence` с исходным предложением и `url` статьи, так что любой вопрос можно проверить руками за минуту. Поле `agent_ok` показывает, ответил ли на вопрос агент на дешёвой модели с поиском и чтением страницы: таких 72, то есть 58 процентов. Это ориентир, а не потолок.

Ваша задача с датасетом, один из двух вариантов на выбор:

- 1. Расширить стартовый набор** не меньше чем на 20 своих вопросов. Тема любая: спорт, наука, кино, технологии, ваш город. Источник любой, но открытый: страница Википедии, новость, официальный сайт. Вопросы можно писать по-русски, если источник русскоязычный, тогда и поиск в агенте должен уметь русский.
- 2. Собрать свой набор** не меньше чем из 40 вопросов на одну тему, которая вам интересна. Формат записей тот же, что в стартовом файле.

Требования к каждому вопросу:

- событие произошло после 1 января 2025 года и до сегодняшнего дня, ничего запланированного и ожидаемого;
- вопрос самодостаточен: по нему понятно, о каком событии речь, без чтения источника;
- ответ короткий и однозначный: имя, число, название, дата. Не «расскажите о», не «почему»;
- ответ дословно содержится в цитате из источника, а цитата в самом источнике.

Критерий свежести, он же главная проверка

В репозитории семинара есть `check_fresh.py`. Без ключа он проверяет формат записей и что ответ дословно есть в цитате. С флагом `--sonnet` прогоняет сильную модель без инструментов по всему набору и печатает долю верных и список вопросов, которые она угадала:

```
python check_fresh.py data/fresh.jsonl --sonnet
```

Доля верных у Sonnet 4.6 должна быть **не выше 20 процентов**. Если выше, вопросы не свежие или ответ угадывается из самого вопроса: такие записи выкидывайте или перепишите. Вывод скрипта приложите к отчёту, это часть оценки.

Шаг 2. Агент

Основа: ноутбук семинара, все семь дырок заполнены. Агент должен уметь отвечать на вопросы вашего набора, и для этого ему нужен доступ к свежей информации.

- **Поиск.** Как минимум `web_search` по Википедии с семинара. Настоятельно рекомендуется второй источник: Tavily (бесплатная тысяча запросов в месяц), DuckDuckGo, поиск по новостному сайту или API, где лежат ваши факты. Если ваши вопросы по-русски, добавьте русскую Википедию: тот же API на `ru.wikipedia.org`.
- **Чтение страницы.** Вступления статьи часто не хватает: факты о 2026 году лежат в теле длинных обзорных страниц вроде «2026 in Japan». Инструмент `page_find(title, keywords)`, который берёт полный текст статьи через тот же API (`prop=extracts` без `exintro`) и возвращает только строки, где встречаются ключевые слова, поднимает долю верных в разы. При сборке стартового набора базовый агент с одним поиском отвечал на 16 процентов вопросов, с чтением страницы на 60. Это отдельный инструмент со своей схемой, описанием и тестами.
- **Остальное с семинара:** калькулятор и `python_exec` остаются, они пригодятся для вопросов с числами и датами.
- **Цикл:** `max_steps`, детектор повторов, мягкое завершение, леджер, трейс каждого прогона в JSON. Всё это уже есть, но должно работать на вашем наборе.

Проверка ответа та же, что на семинаре: нормализованный эталон должен содержаться в ответе. Если ваш ответ дата или число, следите за форматом в `FINAL`: и при необходимости доработайте `is_correct`, но опишите, что изменили.

Шаг 3. Замер

Таблица `report` и картинка `money_chart` на всём вашем наборе. Обязательные строки:

Конфигурация	Зачем она в таблице
сильная модель, без инструментов	строка, которую надо обогнать
дешёвая модель, без инструментов	честный ноль: сколько дешёвая знает сама
дешёвая модель, только поиск	базовый агент с семинара
дешёвая модель, поиск и чтение страницы	ваш лучший агент
средняя модель, ваш лучший набор инструментов	сколько добавляет модель посильнее

По каждой строке: доля верных, цена задачи, цена верного ответа, среднее число шагов, среднее время. Сильная модель только без инструментов и одним вызовом на задачу: она нужна как ориентир, а не как расход бюджета. Каскад из седьмого спринта поверх лучшего агента даёт бонус.

Что сдавать

Репозиторий, который запускается с чистого клона:

- `README.md` : тема набора, откуда факты, как собирали; таблица проверки свежести; итоговая таблица и картинка; абзац с выводом: подтвердился ли тезис курса на вашем наборе, где да, где нет и почему;
- `data/fresh.jsonl` : ваш набор, формат как у стартового;
- ноутбук или скрипты с заполненными дырками и вашими инструментами, у каждого инструмента тест на три случая: нормальный вход, пустой результат, ошибка;
- папка `traces` с трейсами итогового прогона;
- два разобранных провала: ссылка на трейс и одна фраза, что именно сломалось: поиск не нашёл, нашёл не то, нашёл, но модель не прочла, ответ верный, но не прошёл проверку;
- `.env.example` ВМЕСТО `.env` , `requirements.txt` , ключа в истории коммитов нет.

Оценка, 10 баллов

Критерий	Баллы
Репозиторий запускается с чистого клона, ключа в истории нет	2
Датасет по требованиям, проверка свежести приложена, Sonnet не выше 20 процентов	2
Агент с поиском и чтением страницы, инструменты с тестами	2
Таблица со всеми обязательными строками и картинка	2
Два разобранных провала и честный вывод по тезису	2
Бонус: каскад поверх лучшего агента, строка в таблице и точка на картинке	+1
Бонус: второй источник поиска кроме Википедии, сравнение с ним и без	+1

Оценка не зависит от того, подтвердился тезис или нет. Зависит от того, честно ли посчитано. Результат «агент на дешёвой модели дороже и хуже» с разбором, почему, стоит столько же, сколько победа.

Бюджет

Свежие вопросы дороже арифметики: у агента больше шагов и длинные результаты поиска в контексте. Ориентир: 60 вопросов в пяти конфигурациях на дешёвой и средней модели плюс сильная без инструментов обходятся в один-два доллара. Если счётчик в леджере ушёл за пять, остановитесь и посмотрите трейсы: скорее всего, агент зациклился, а детектор не сработал.

Часть 2, опциональная: свой агент к концу курса

Для тех, кто хочет к финалу курса иметь не учебный, а собственный агент. Эта часть не обязательна, но всё, что вы сделаете здесь, станет заделом финального проекта и будет засчитано там.

Шаг 1. Описание задачи

Одна страница текста, не больше. Кто пользователь и какую работу он делает руками сегодня. Что агент должен уметь, чтобы эту работу забрать. Как выглядит «сделано»: какой результат, в каком виде, с какой точностью. Какие данные и API у вас есть на самом деле, а не в мечтах. Какие ошибки агента опасны, а какие терпимы.

До того как писать код, обсудите описание с @artemovma в телеграме. Половина идей на этом шаге меняется: задача либо слишком большая для шести недель, либо решается одним запросом к модели без всякого агента. Лучше узнать это до реализации.

Шаг 2. Силлы

Продумайте и реализуйте **не меньше четырёх-пяти скиллов**: инструментов, которые агенту понадобятся для вашей задачи. Скилл это то же, что инструмент на семинаре, только из вашей

предметной области.

Каждый скилл:

- функция с внятным именем и Pydantic-моделью аргументов, у каждого поля описание: это часть промпта, модель выбирает инструмент по ним;
- описание, из которого понятно, когда его звать, а когда нет;
- обработка ошибок: пустой результат и ошибка возвращаются текстом, а не роняют программу;
- **проверка работы:** тест не меньше чем на три случая, нормальный вход, пустой результат, ошибка. Тесты запускаются без модели и без ключа;
- **обёртка:** скилл регистрируется через `register` из семинара и виден агенту как инструмент со схемой. Модель на этом шаге опциональна: достаточно, чтобы схема печаталась и `run_tool` умел его вызвать.

Примеры, чтобы было от чего оттолкнуться:

- **ассистент по документам:** найти файл по смыслу, вытащить таблицу из PDF, сравнить две версии, сохранить сводку;
- **поддержка пользователей:** найти тикет, проверить статус заказа в базе, посчитать возврат по правилам, сформировать ответ по шаблону, эскалировать человеку;
- **аналитика:** выполнить SQL по описанию, построить график, проверить данные на пропуски, сравнить с прошлым периодом;
- **личный планировщик:** прочесть календарь, найти свободный слот, составить письмо, проверить погоду и дорогу;
- **разработка:** запустить тесты, прочесть лог ошибки, найти похожую проблему в issues, предложить патч.

Ни один из примеров не обязателен. Задача должна быть вашей: той, где вы сами пользователь или хорошо знаете пользователя.

Что сдавать во второй части

Отдельный репозиторий или папка `project` в основном. Внутри `task.md` с описанием задачи и пометкой, что оно обсуждено, папка `skills` с реализациями, тесты, которые проходят командой `python -m pytest` или одним скриптом, и короткий `README` : как запустить тесты и как посмотреть схемы скиллов. Оценивается как бонус к первой части, до трёх баллов, и переносится в зачёт финального проекта.

Вопросы по заданию в чат курса. Проблемы с ключом и бюджетом: @artemovma в телеграме. Следующая неделя: память и RAG, ваш агент получит долгую память и поиск по документам поверх того, что вы сдадите.